

Previsão de Churn em Telecom

Do Problema de Negócio à Decisão Estratégica

Projeto de Portfólio – Ciência de Dados 

Storytelling Executivo: Do Problema à Decisão

Desafio de Negócio

Definição do impacto financeiro do Churn e o objetivo de antecipar cancelamentos para proteger a receita recorrente.

1



Análise Exploratória & Pipeline

Ingestão via SQL, tratamento em Python e descoberta dos principais ofensores.

2



Modelagem Preditiva

Desenvolvimento do algoritmo (Regressão Logística) calibrado para maximizar a detecção de clientes em risco (Recall).

3



Dashboard Decisório

Tradução do modelo técnico para uma interface no Power BI que permite segmentação rápida por nível de risco.

4



Estratégia de Retenção

Plano de ação prático: como a empresa usa essa inteligência para focar esforços, reduzir churn e aumentar o LTV.

5



O Desafio

O Churn não é apenas uma métrica; é o maior detrator de crescimento no setor de Telecom. Atualmente, perdemos receita mais rápido do que conseguimos repor.

Como identificar o cliente em risco *antes* que ele tome a decisão de sair?

Impacto no Negócio

1

CAC vs Retenção: Conquistar um novo cliente custa até 5x mais do que reter o atual.

Perda Invisível: Cada cancelamento não é apenas uma perda pontual, mas uma redução drástica no *Lifetime Value* (LTV) da carteira.

- Churn reduz LTV
- CAC é maior que custo de retenção
- Antecipar churn significa proteger receita.

A Proposta de Valor

1

Mudar a chave de **Reativo** para **Preditivo**. Utilizaremos Inteligência Artificial para identificar o risco de saída *antes* que o cliente tome a decisão.

Pipeline de Solução

2

SQL (Extração) → Python (Refinamento) → Feature Engineering → ML → Power BI

O Que os Dados Mostraram (EDA)

2

A análise exploratória revelou que contratos mensais apresentam maior instabilidade, clientes de fibra óptica tendem a cancelar mais e contratos de longo prazo reduzem significativamente a chance de churn.

Preparação dos Dados

2

- Limpeza e padronização dos dados.
- Codificação de variáveis categóricas.
- Criação de variáveis para modelagem.

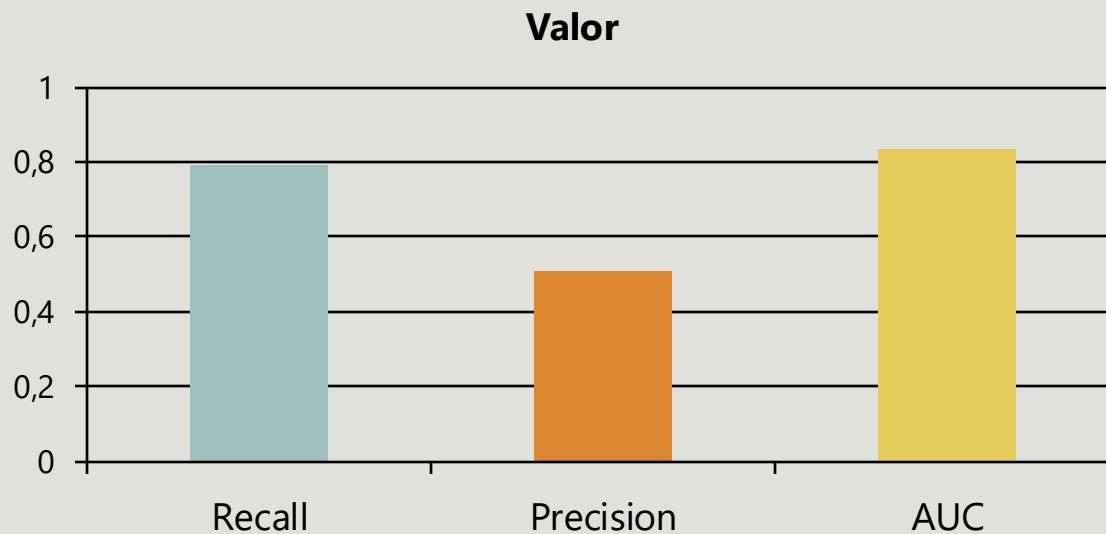
Modelagem

3

Foram testados diferentes modelos preditivos, com foco principal na métrica Recall, garantindo que a maior parte dos clientes em risco fosse identificada. O modelo que apresentou melhor equilíbrio entre desempenho e interpretação foi a Regressão Logística.

Resultado do Modelo

O modelo final alcançou alto Recall, sendo capaz de identificar a maioria dos clientes com risco de churn. Ele mantém boa performance ao mesmo tempo em que é simples e fácil de explicar para áreas de negócio.

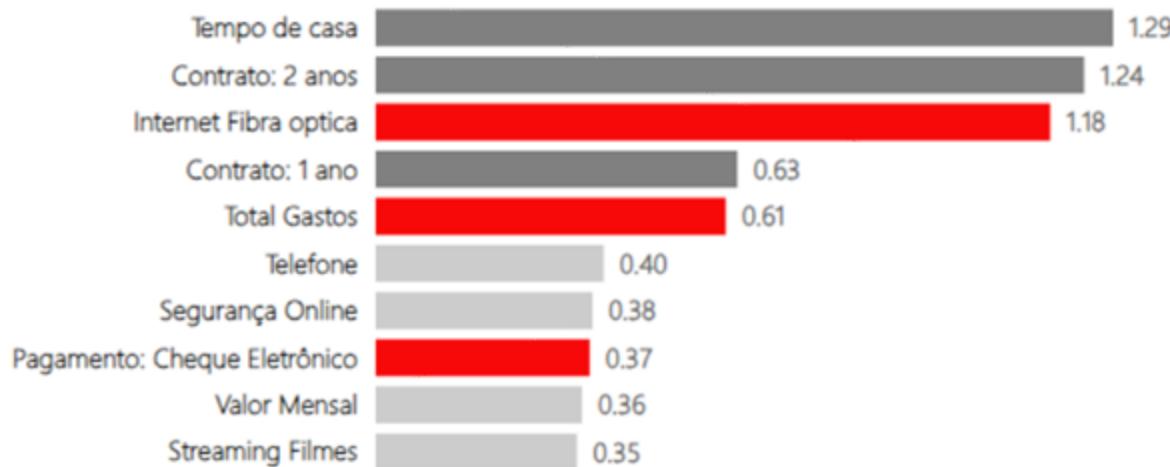


Principais Fatores de Churn

3

Os fatores mais influentes no churn foram o tipo de contrato, a forma de pagamento e os serviços contratados. Esses elementos explicam grande parte do comportamento de cancelamento dos clientes.

Principais Fatores de Churn (Modelo)



Validação

As relações identificadas foram confirmadas estatisticamente por meio de três testes fundamentais:

- **Shapiro-Wilk** para avaliar a normalidade dos dados;
- **Mann-Whitney** para comparar grupos **com** e **sem** churn;
- **Chi-Quadrado** para validar associações entre variáveis categóricas.

Os resultados mostraram que tipo de contrato e forma de pagamento impactam diretamente o churn, enquanto contratos mais longos reduzem de forma consistente o risco de cancelamento, garantindo maior confiança nas conclusões do projeto.

Entrega no Power BI

4

O resultado foi traduzido em um dashboard no Power BI com métricas do modelo, visualização dos fatores de churn e uma tabela de priorização por nível de risco, usando cores para facilitar a tomada de decisão.

Estratégia de Retenção

5

A empresa pode priorizar clientes com risco acima de 80%, oferecer migração para contratos mais longos e agir antes que o cliente decida cancelar.

Impacto Esperado

5

Com essa abordagem, espera-se reduzir o churn, aumentar o LTV e diminuir a perda financeira associada ao cancelamento de clientes.

Conclusão

O projeto conecta dados à decisão, usando um modelo simples, interpretável e pronto para aplicação real, apoiando estratégias de retenção baseadas em dados.